



Universidad Veracruzana
Facultad de Estadística e Informática

Lic. en Ingeniería en Ciencia de Datos

Metodología de la Investigación
KDD

Equipo 8:

Diego Iván González Colorado
Susana Elizabeeth Isidoro Caporal
Cristian Eduardo Montesino Fernández

Docente: Lorena López Lozada

15 de Septiembre del 2026

METODOLOGÍA KDD EN EL USO DE TIK TOK

Introducción

Este documento describe, paso a paso, el proceso de Descubrimiento de Conocimiento en Bases de Datos (KDD, por sus siglas en inglés) aplicado al conjunto de datos utilizado para la investigación sobre el uso de la aplicación TikTok. El KDD es el proceso general y no automático mediante el cual se identifican patrones válidos, novedosos, útiles y comprensibles a partir de grandes volúmenes de datos (Fayyad, Piatetsky-Shapiro y Smyth, 1996), en ese sentido, las fases que se utilizaron fueron las siguientes: (1) Selección, (2) Recolección, (3), Limpieza y preprocesamiento, (4) Transformación, (5) Minería de datos y (6) Interpretación / Evaluación y (7) Presentación del conocimiento.

Ahora bien, para poder realizar lo anterior, fue a partir de tres fuentes: la base de datos original con su documentación ("KBailey_MRes_dataset_with_documentation.xlsx"), la base de datos ya depurada y transformada ("Baselimpia.xlsx"), y los resultados del análisis estadístico y algorítmico ya ejecutado sobre esta última (comparación de medias, correlación, regresión lineal múltiple y segmentación por K-Medias).

Fase 1 y 2: Selección y recolección de los datos

En esta primera fase se definió la fuente de datos y la población de estudio a partir de la cual se construiría el análisis.

Fuente y descripción general de los datos

Se seleccionó el conjunto de datos públicos "TikTok Usage in the UK and USA, 2026" del repositorio institucional BORDaR de Bournemouth University, por tratarse de una base de acceso abierto, con documentación oficial de variables (hoja Index), objetivos de investigación afines al tema de estudio (uso de TikTok, factores demográficos y de personalidad, y motivación de uso) y una muestra de ($N = 361$).

Repositorio: BORDaR — Bournemouth Online Research Data Repository (Bournemouth University).

Referencia del recurso: Bailey, K. E. (2026). TikTok Usage in the UK and USA, 2026 [Conjunto de datos]. Bournemouth University. <https://doi.org/10.18746/bmth.data.00000533> — Disponible en: <https://bordar.bournemouth.ac.uk/533/>

Investigación asociada: "TikTok Usage in the UK and USA: Investigating the Role of Demographic Factors, Personality Traits, and User Motivation" (tesis de maestría, Bournemouth University).

De acuerdo con la ficha del repositorio, los datos se recolectaron mediante una encuesta en línea administrada con Qualtrics, entre febrero de 2024, con participantes reclutados a través de las plataformas Sona Systems (estudiantes de psicología de Bournemouth University) y Prolific (público general). Los criterios de inclusión fueron: tener 18 años o más, hablar inglés con fluidez, residir en el Reino Unido o en Estados Unidos, y ser usuario activo de TikTok (haber accedido a la aplicación al menos una vez en los 30 días previos). El estudio contó con aprobación ética del Comité de Ética en Investigación de Bournemouth University y los participantes otorgaron consentimiento informado electrónico; el conjunto de datos es anónimo y se distribuye bajo licencia Creative Commons Attribution 4.0.

Estructura del archivo original

El archivo original ("KBailey_MRes_dataset_with_documentation.xlsx") contiene dos hojas:

- **Dataset:** la matriz de datos propiamente dicha, con 361 casos (participantes) y 47 variables.
- **Index:** un diccionario de variables (codebook) que describe el nombre y el significado de cada una de las 47 columnas del Dataset.

Esta estructura es la que permitió reconstruir con precisión el significado de cada variable durante las fases de selección y transformación descritas más adelante.

Aspecto	Base original (Dataset)	Base limpia (Baselimpia)
Nº de casos (filas)	361	361
Nº de variables (columnas)	47	27
Valores perdidos (missing)	0 (ninguna celda vacía detectada)	0
Filas duplicadas	0	0
Formato	.xlsx, hoja "Dataset" + hoja "Index" (diccionario)	.xlsx, hoja única "Hoja1"

Población y muestra

La muestra seleccionada corresponde a los 361 participantes que completaron la encuesta original, sin exclusión adicional de casos (no se eliminó a ningún participante), ya que no se detectaron valores perdidos ni registros duplicados. La composición de la muestra es la siguiente:

Variable	Categorías y frecuencias
Plataforma de reclutamiento	Prolific = 264 (73.1%) Sona = 97 (26.9%)
Nacionalidad	Reino Unido (UK) = 261 (72.3%) Estados Unidos (USA) = 100 (27.7%)
Género	Femenino = 270 (74.8%) Masculino = 91 (25.2%)
Generación	Gen Z = 203 (56.2%) Millennials = 119 (33.0%) Gen X = 36 (10.0%) Baby Boomers = 3 (0.8%)
Edad	Mínimo = 18 años, máximo = 68 años, media $\approx$ 28.7 años

Selección preliminar de variables

De las 47 variables originales documentadas en la hoja Index, se hizo una primera revisión conceptual identificando ocho grandes bloques temáticos: (1) identificación del canal de reclutamiento, (2) datos demográficos, (3) uso de redes sociales adicionales a TikTok, (4) perfil y hábitos de uso de TikTok, (5) uso autorreportado (estimado por el propio participante), (6) datos reales de uso de la app, (7) percepción de la diferencia entre lo estimado y lo real, (8) rasgos de personalidad (BFI-10) y (9) motivaciones de uso (Motives for TikTok Use). Esta agrupación temática fue la base para decidir, en la fase de transformación, qué variables se conservarían para el análisis.

Fase 3: Limpieza y preprocesamiento de los datos

En esta fase se verificó la calidad de los datos antes de transformarlos. Se revisaron cuatro aspectos: valores faltantes, registros duplicados, consistencia interna entre variables relacionadas, y coherencia de las categorías declaradas frente al diccionario de variables (hoja Index).

Verificación realizada	Resultado	Acción tomada
Valores perdidos (missing values) en las 47 variables	0 celdas vacías detectadas en los 361 casos	No fue necesario imputar ni eliminar casos
Registros (filas) duplicados	0 filas duplicadas	No se eliminó ningún caso
Consistencia: Horas día + Horas noche = Horas totales (App_Data_Hours)	Diferencia máxima $\approx$ 0.01 h (error de redondeo, no de captura)	Se conservó como válido
Consistencia: N° de aperturas día + noche = aperturas totales	Diferencia = 0 en todos los casos	Se conservó como válido

Tipos de dato por columna (edad, seguidores, horas, escalas, etc.)	Consistentes con lo esperado (enteros, decimales, texto categórico, hora hh:mm)	Sin cambios de tipo necesarios
Categorías declaradas vs. diccionario (Index)	En general coinciden; en "TikTok_Duration" el Index resume las categorías como "menos de un año, 1-4 años, 5 años o más", mientras que en los datos aparecen registradas de forma más granular (1, 2, 3, 4 años)	Se documenta como observación; no se modificaron las categorías originales

Fase 4: Transformación de los datos

La transformación se centró en una reducción de dimensionalidad por selección de atributos (feature selection): de las 47 variables originales se conservaron 27, orientando la base de datos limpia hacia las variables directamente relevantes para el objetivo de la investigación (perfil demográfico, hábitos y uso de TikTok, y motivaciones de uso), y excluyendo variables redundantes o fuera del enfoque analítico final.

Variables eliminadas

Bloque temático	Variables eliminadas	Justificación
Identificación del reclutamiento	Platform, Nationality	Variables de control del proceso de muestreo; no forman parte de las hipótesis centrales sobre comportamiento y motivación de uso.
Redes sociales adicionales	Facebook, Twitter, Messenger, Snapchat, Threads, Discord, BeReal, WhatsApp, Other	Se conservó solo el uso de Instagram y YouTube (las más relevantes como comparación con TikTok); el resto de plataformas se eliminó por baja relevancia para el análisis y para reducir dimensionalidad.
Formato duplicado de tiempo de uso	App_Data_Hours_Day_hh:mm, App_Data_Hours_Night_hh:mm, App_Data_Hours_Total_hh:mm	Estas columnas duplican en formato hora:minuto (hh:mm) la misma información que ya está expresada

		en formato decimal (_2dp); se conservó únicamente el formato decimal por ser más manejable para el análisis estadístico.
Percepción subjetiva de la diferencia	Surprised_by_Difference	Variable de opinión complementaria, no indispensable para los indicadores de uso y personalidad que se analizarán.
Rasgos de personalidad (BFI-10)	Extraversion, Agreeableness, Conscientiousness, Neuroticism, Openness	Se excluyó el bloque completo de personalidad (Big Five), enfocando la base limpia en el bloque de motivaciones de uso (Motives for TikTok Use) en lugar de en los rasgos de personalidad.

Variables conservadas

Bloque temático	Variables conservadas
Datos demográficos (5)	Age, Gender, Generation, Education_Level, Job_Status
Uso de otras redes sociales (2)	Instagram, YouTube
Perfil y hábitos de uso de TikTok (8)	TikTok_Profile_Status, TikTok_Duration, Followers, Following, Profile_Likes, Number_of_Profiles, TikTok_for_Business, Usage_since_COVID
Uso autorreportado / estimado (2)	Estimate_Hours, Estimate_Times_Opened
Datos reales de uso de la app (6)	App_Data_Hours_Day_2dp, App_Data_Hours_Night_2dp, App_Data_Hours_Total_2dp, App_Data_Times_Opened_Day, App_Data_Times_Opened_Night, App_Data_Times_Opened_Total
Motivaciones de uso — Motives for TikTok Use (4)	Socially_Rewarding_Self_Presentation, Trendiness, Escapist_Addiction, Novelty

Fase 5: Minería de datos — resultados

Con la base de datos ya seleccionada, limpia y transformada (Baselimpia.xlsx, 361 casos × 27 variables), se aplicaron cuatro técnicas de minería de datos sobre las variables de uso real de la aplicación (App_Data_Hours_Total_2dp, App_Data_Times_Opened_Total), el uso autorreportado

(Estimate_Hours, Estimate_Times_Opened), las motivaciones de uso (Socially_Rewarding_Self_Presentation, Trendiness, Escapist_Addiction, Novelty) y los indicadores de perfil (Followers, Following, Profile_Likes).

Comparación entre el uso estimado y el uso real

Se compararon las horas y el número de aperturas que los propios participantes estimaron haber usado TikTok, frente a los datos reales registrados por la aplicación, mediante prueba t pareada y prueba de Wilcoxon (para verificar el resultado sin asumir normalidad).

Comparación	Media estimada	Media real (app)	Prueba t pareada (p)	Wilcoxon (p)	Resultado
Horas de uso semanal	20.35 h	16.54 h	0.000	0.000	Diferencia estadísticamente significativa
Nº de veces que se abrió la app	44.94 veces	90.77 veces	0.000	0.000	Diferencia estadísticamente significativa

En ambos casos los participantes muestran una percepción distinta a la registrada por la app: subestiman notablemente el número de veces que abren TikTok (44.94 estimadas frente a 90.77 reales) y sobrestiman las horas totales de uso (20.35 h estimadas frente a 16.54 h reales).

Correlación entre motivaciones de uso y patrones de uso real

Se calcularon los coeficientes de correlación de Pearson y de Spearman entre las cuatro motivaciones de uso y las dos variables de uso real (horas totales y número de aperturas totales).

Variable de uso	Motivación	Pearson (r, p)	Spearman (rho, p)	Lectura
Horas totales de uso	Socially Rewarding Self-Presentation	n.s. (p = 0.181)	rho=0.114 (p=0.030)	Relación positiva débil, solo significativa en Spearman
Horas totales de uso	Trendiness	n.s. (p = 0.221)	rho=0.122 (p=0.021)	Relación positiva débil,

				solo significativa en Spearman
Horas totales de uso	Escapist Addiction	n.s. (p = 0.065)	rho=0.196 (p=0.000)	Relación positiva moderada y altamente significativa
Horas totales de uso	Novelty	No significativa	No significativa	Sin relación con el uso en horas
Nº de veces que se abrió la app	Socially Rewarding Self-Presentation	No significativa	No significativa	Sin relación con la frecuencia de apertura
Nº de veces que se abrió la app	Trendiness	r=0.125 (p=0.018)	rho=0.132 (p=0.012)	Relación positiva débil y significativa
Nº de veces que se abrió la app	Escapist Addiction	r=0.270 (p=0.000)	rho=0.363 (p=0.000)	Correlación más fuerte encontrada en todo el análisis
Nº de veces que se abrió la app	Novelty	No significativa	No significativa	Sin relación con la frecuencia de apertura

Regresión lineal múltiple

Se construyeron dos modelos de regresión lineal múltiple, usando las cuatro motivaciones de uso como predictoras de (a) las horas totales de uso y (b) el número total de aperturas de la app.

Variable dependiente	R ² (ajustado)	Significancia del modelo (F, p)	Predictora(s) significativa(s)
----------------------	---------------------------	---------------------------------	--------------------------------

App_Data_Hours_Total_2dp (horas de uso)	0.030 (0.019)	p = 0.031 — significativo	Escapist_Addiction (p = 0.005; coef. = 0.443)
App_Data_Times_Opened_Total (veces abierta)	0.074 (0.064)	p = 1.57e-05 — altamente significativo	Escapist_Addiction (p = 0.000; coef. = 8.081)

En ambos modelos, Escapist_Addiction es la única motivación con efecto estadísticamente significativo, aunque el poder explicativo global de los modelos es bajo (R^2 entre 3.0% y 7.4%), lo que indica que la mayor parte de la variación en el uso de TikTok se explica por otros factores no incluidos en el modelo de motivaciones.

Segmentación de usuarios (K-Medias)

Para identificar perfiles de usuario según sus hábitos de uso, se aplicó el algoritmo de agrupamiento K-Means sobre las variables Followers, Following, Profile_Likes, App_Data_Hours_Total_2dp y App_Data_Times_Opened_Total (previamente escaladas). El número óptimo de clusters se estimó con el método del codo (gráfico de la suma de errores cuadrados, SSE):




Figura 1. Método del codo (SSE) sobre la base completa (361 casos).

Con base en el punto de inflexión del gráfico, se eligió $K = 3$ como primera aproximación. Los tres conglomerados resultantes fueron:

Cluster	N	Followers (media)	Following (media)	Profile_Likes (media)	Horas de uso (media)	Veces abierta (media)	Perfil
0	279	≈525	≈495	≈13,457	≈2.3 h	≈55	Usuarios ligeros / promedio
1	81	≈1,462	≈1,021	≈13,654	≈15.2 h	≈212	Usuarios activos
2	1	≈234,000	≈23	≈4,200,000	≈0.7 h	≈134	Usuario atípico (influencer / outlier)

Ajuste metodológico: tratamiento del valor atípico

El Cluster 2 quedó conformado por un único caso extremo, con un número de seguidores y 'me gusta' varios órdenes de magnitud por encima del resto de la muestra (≈234,000 seguidores y ≈4.2 millones de likes), este caso distorsionaba la segmentación general, por lo que se decidió eliminarlo del análisis y recalcular la agrupación, quedando 360 casos, en consecuencia, se generó un nuevo gráfico del método del codo sobre los datos sin el outlier; a partir de éste se eligió K = 2 como número final de conglomerados.

Con los 360 casos restantes y K = 2, la nueva distribución de usuarios y sus características medias fueron las siguientes:

Cluster	N	Followers (media)	Following (media)	Profile_Likes (media)	Horas de uso (media)	Veces abierta (media)	Perfil
0	356	≈501.5	≈613.7	≈6,218	≈5.3 h	≈89.7	Usuarios típicos / promedio
1	4	≈21,558	≈552.5	≈661,700	≈0.6 h	≈173.8	Usuarios con perfil de alto alcance (muchos seguidores y 'likes', pero bajo tiempo de uso)




Figura 2. Características medias de los clusters finales (K = 2, sin el outlier).

El Cluster 0 concentra a la gran mayoría de la muestra (356 de 360 casos) y representa al usuario típico: seguidores, seguidos y 'likes' moderados, con un uso semanal de la app de aproximadamente 5.3 horas y 89.7 aperturas. El Cluster 1, mucho más pequeño (4 casos), agrupa a usuarios con un alcance social muy superior a la media (miles de seguidores y cientos de miles de 'likes'), pero con un tiempo de uso notablemente bajo (0.6 h) y una frecuencia de apertura más alta (173.8 veces); un patrón compatible con cuentas de alto perfil que publican o revisan interacciones de forma breve y frecuente, sin permanecer largos periodos dentro de la app.

Fase 6: Interpretación y evaluación de los resultados

En esta última fase se interpretan los hallazgos de la minería de datos a la luz del objetivo de la investigación ("TikTok Usage in the UK and USA: Investigating the Role of Demographic Factors, Personality Traits, and User Motivation") y se valora su solidez y alcance.

Percepción vs. uso real

La diferencia estadísticamente significativa entre el uso estimado y el uso real indica que los participantes tienen una percepción distorsionada de su propio comportamiento en TikTok: subestiman con claridad cuántas veces abren la aplicación (más del doble en la realidad que en su propia estimación) y, en cambio, sobrestiman ligeramente el tiempo total que le dedican. Este hallazgo es consistente con la literatura sobre el sesgo de autopercepción en el uso de redes sociales y respalda el valor añadido de usar datos objetivos de la app (screen time) en lugar de apoyarse únicamente en el autorreporte.

Motivaciones de uso

De las cuatro motivaciones evaluadas, únicamente Escapist_Addiction (adicción escapista) mostró una relación consistente, positiva y estadísticamente significativa tanto con las horas de uso como con la frecuencia de apertura, y fue la única predictora significativa en ambos modelos de regresión. Trendiness (estar a la moda) mostró una asociación positiva débil, pero únicamente con la frecuencia de apertura. Socially_Rewarding_Self_Presentation y Novelty no mostraron relación significativa con los patrones de uso real. Esto sugiere que, en esta muestra, el impulso a evadirse o distraerse (más que la búsqueda de reconocimiento social o de contenido novedoso) es el motivador más asociado al uso intensivo de la app. No obstante, el bajo poder explicativo de los modelos (R^2 de 3.0% y 7.4%) indica que las motivaciones evaluadas explican solo una fracción pequeña del uso real, y que factores no incluidos en este análisis (por ejemplo, variables demográficas, de personalidad o contextuales) probablemente inciden también de forma relevante.

Perfiles de usuario

La segmentación por K-Medias evidenció, en primer lugar, la fuerte asimetría de variables como Followers y Profile_Likes: un único caso extremo (influencer) fue suficiente para formar su propio conglomerado en el primer intento ($K = 3$), lo que metodológicamente obligó a tratarlo como valor atípico y recalcular la segmentación. Tras excluirlo, la segmentación final ($K = 2$) confirma que la inmensa mayoría de los usuarios (356 de 360, $\approx 98.9\%$) se comporta de manera relativamente homogénea (uso moderado, alcance social moderado), mientras que un grupo muy reducido (4 casos, $\approx 1.1\%$) combina un alcance social considerablemente mayor con un patrón de uso breve pero frecuente. Esto sugiere que, más que hábitos de uso marcadamente distintos entre 'tipos' de usuario, lo que diferencia a estos casos particulares es principalmente su nivel de exposición/alcance dentro de la plataforma.

Evaluación general

- Validez estadística: las pruebas de comparación de medias (t pareada y Wilcoxon) y la correlación de Escapist_Addiction son sólidas ($p < 0.05$, y en varios casos $p < 0.001$), por lo que constituyen hallazgos confiables dentro de esta muestra.
- Limitación principal: el bajo R^2 de los modelos de regresión indica que las cuatro motivaciones evaluadas no son, por sí solas, suficientes para explicar el uso real de TikTok; se recomienda, como trabajo futuro, incorporar variables demográficas y/o de personalidad para mejorar el poder explicativo del modelo.
- Sensibilidad a valores atípicos: el ejercicio de clustering mostró la importancia de revisar la presencia de outliers antes de interpretar los conglomerados, ya que un solo caso extremo puede distorsionar la segmentación completa.

- Utilidad práctica: los resultados aportan evidencia de que el diseño de intervenciones o mensajes sobre uso saludable de TikTok podría beneficiarse más de abordar motivaciones de tipo escapista que de estrategias enfocadas en la novedad o el reconocimiento social.

Conclusión general

El proceso KDD documentado en este informe permitió pasar de una base de datos pública de 361 casos y 47 variables a una base de trabajo depurada de 361 casos y 27 variables (fases de selección, limpieza y transformación), sobre la cual se aplicaron y documentaron técnicas de minería de datos —comparación de medias, correlación, regresión lineal múltiple y clustering K-Means— para finalmente interpretar los resultados obtenidos. Los principales hallazgos son: (1) existe una diferencia significativa entre el uso de TikTok que los usuarios estiman y el que realmente realizan; (2) de las motivaciones de uso evaluadas, la adicción escapista (Escapist_Addiction) es la que más consistentemente se asocia con un mayor uso de la app, aunque con un poder explicativo limitado; y (3) la segmentación de usuarios reveló un grupo mayoritario con hábitos de uso homogéneos y un grupo minoritario de usuarios con un alcance social considerablemente mayor, un hallazgo que exigió un tratamiento cuidadoso de valores atípicos. En conjunto, estos resultados dan respuesta preliminar a la pregunta de investigación y sientan las bases para análisis futuros que incorporen otras variables del conjunto original (por ejemplo, personalidad o nacionalidad) para profundizar en la explicación del comportamiento de uso de TikTok

Referencias

- Bailey, K. E. (2026). *TikTok Usage in the UK and USA, 2026* [Conjunto de datos]. Bournemouth University. <https://doi.org/10.18746/bmth.data.00000533>
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37–54.
- Maimon, Oded & Rokach, Lior. (2005). Chapter 1 - Introduction to Knowledge Discovery in Databases. https://www.researchgate.net/publication/225835494_Chapter_1_-_Introduction_to_Knowledge_Discovery_in_Databases